

**UNIVERSITATEA DIN BUCUREȘTI FACULTATEA DE
MATEMATICĂ ȘI INFORMATICĂ**

LUCRARE DE LICENȚĂ

Coordonator:
Prof. Dr. Radu Ionescu

Absolvent:
Moldovan George-Alexandru

București
Iunie (fingers crossed), 2020

**UNIVERSITATEA DIN BUCUREȘTI FACULTATEA DE
MATEMATICĂ ȘI INFORMATICĂ**

Sistem pentru detectarea anomaliilor in video

Coordonator:
Prof. Dr. Radu Ionescu

Absolvent:
Moldovan George-Alexandru

București
Iunie (fingers crossed), 2020

Contents

1	Introdúcere	1
1.1	Motivatíe	1
1.2	Context	1
2	Plictíseala	3

Abstract

Având în vedere contextul actual, detectarea anomaliilor în video este un subiect de interes în mai multe arii, în mod special în securitatea publică. Aceasta problemă putem spune că este încă nerezolvată, deoarece sistemele actuale nu depășesc deocamdata omul când vine vorba de detectarea anomaliilor. De asemenea, o altă problemă a sistemelor de detectare a anomaliilor în video este nevoia acestora de resurse computaționale mari în partea de inferență, făcând aproape imposibilă rularea acestora direct pe hardware-ul existent al sistemelor de supraveghere video actuale, acolo unde acestea prezintă un maxim interes. Aceasta lucrare își propune o implementare al sistemului state-of-the-art la momentul redactării, așa cum este prezentat de *Ionescu et al.* [3]. Obiectivul este obținerea unei arhitecturi serverless și expunerea etapei de inferență printr-un API astfel încât convertirea unui sistem de supraveghere clasic într-unul inteligent să devină doar o problemă de implementare, fără a fi nevoie de schimbarea hardware-ului. Utilizarea unei arhitecturi serverless bazate pe funcții stateless în cloud rezolvă problema executării codului on-demand fără complexitatea creerii și întreținerii unei infrastructuri de mașini virtuale sau fizice. Numeroase lucrări din domeniu [2, 5] arată că rularea algoritmilor de machine learning folosind soluții FaaS (Function as a service) precum AWS Lambda sau Google cloud functions, este în sine o problemă ce necesită soluții de optimizare a codului pentru a îndeplini restricțiile soluțiilor de rulare în cloud.

Chapter 1

Introducere

1.1 Motivatie

Detectarea anomaliilor in video este in strânsă legatură cu sistemele de supraveghere inteligente, un domeniu care a fost si este de interes pentru mine. La rândul lor, sistemele de supraveghere inteligente, au o mare importanță in securitatea publică. Cred că cu toții ne dorim o lume in care apelurile de urgență in caz de incendiu se fac automat, alunecările de teren sunt descoperite înainte să fie prea târziu, iar oamenii rău intenționați sunt opriți inainte să se întâmple tragedii. Pe lângă partea algoritmica a detectării anomaliilor, o alta arie de interes a acestei lucrări este cloud computing. Această parte analizează un nou mod de rulare, ce facilitează atât dezvoltarea cât si execuția ulterioară a unor sisteme complexe. Acest nou mod constă in folosirea unei arhitecturi serverless, ce oferă dezvoltatorului posibilitatea să creeze sisteme ce necesită multe resurse in timpul rulării, fara costurile asociate creeri si menținerii unei infrastructuri proprii. Pe de altă parte, având in vedere că toate operațiunile sunt executate in cloud, utilizatorii serviciului au nevoie doar de conexiune la internet și cerințe minime pentru sistemele proprii, fara a fi nevoiți să achiziționeze echipamente noi pentru a folosi sisteme de detecție a anomaliilor.

1.2 Context

Detectarea anomaliilor in video poate fi văzută ca o problemă subiectivă, deoarece un eveniment este normal sau anormal doar dacă este luat în considerare și contextul în care acesta apare. Un exemplu foarte bun este lupta între două persoane si o persoană care se plimbă. Care dintre aceste evenimente este anormal ? Desigur, depinde de context. Dacă sistemul supraveghează o arena de lupte, atunci persoana care se plimbă in ring prezintă un comportament anormal, in timp ce luptătorii prezintă comportamentul așteptat. Din acest motiv majoritatea lucrărilor din domeniu [1, 3, 4]... abordează un mod de lucru bazat pe antrenarea folosind video-uri ce provin din aceeasi locație cu cele de test. Tocmai din cauza dependenței de context, detectarea

anomaliilor nu este o problemă ce poate fi generalizată, astfel fiecare scenariu necesită o antrenare și un model propriu.

Chapter 2

Plictiseala

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language. Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language. Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Bibliography

- [1] K. Cheng, Y. Chen, and W. Fang. Video anomaly detection and localization using hierarchical feature representation and gaussian process regression. pages 2909–2917, 2015.
- [2] A. Christidis, R. Davies, and S. Moschoyiannis. Serving machine learning workloads in resource constrained environments: a serverless deployment example. pages 55–63, 2019.
- [3] R. T. Ionescu, F. S. Khan, M. Georgescu, and L. Shao. Object-centric auto-encoders and dummy anomalies for abnormal event detection in video. pages 7834–7843, 2019.
- [4] W. Sultani, C. Chen, and M. Shah. Real-world anomaly detection in surveillance videos. pages 6479–6488, 2018.
- [5] H. Wang, D. Niu, and B. Li. Distributed machine learning with a serverless architecture. pages 1288–1296, 2019.